



**MATEMATICKO-FYZIKÁLNÍ
FAKULTA**
Univerzita Karlova

BAKALÁŘSKÁ PRÁCE

Viktor Němeček

Percepční učení a Ideální Bayesovský pozorovatel při zrakovém vyhledávání

Katedra softwaru a výuky informatiky

Vedoucí bakalářské práce: Mgr. Filip Děchtěrenko, Ph.D.

Studijní program: Informatika

Studijní obor: Obecná informatika

Praha 2018

Prohlašuji, že jsem tuto bakalářskou práci vypracoval(a) samostatně a výhradně s použitím citovaných pramenů, literatury a dalších odborných zdrojů.

Beru na vědomí, že se na moji práci vztahují práva a povinnosti vyplývající ze zákona č. 121/2000 Sb., autorského zákona v platném znění, zejména skutečnost, že Univerzita Karlova má právo na uzavření licenční smlouvy o užití této práce jako školního díla podle §60 odst. 1 autorského zákona.

V dne

Podpis autora

Poděkování.

Název práce: Percepční učení a Ideální Bayesovský pozorovatel při zrakovém vyhledávání

Autor: Viktor Němeček

Katedra: Katedra softwaru a výuky informatiky

Vedoucí bakalářské práce: Mgr. Filip Děchtěrenko, Ph.D., Katedra softwaru a výuky informatiky

Abstrakt: Abstrakt.

Klíčová slova: klíčová slova

Title: Perceptual learning and Ideal Bayesian observer in visual search task

Author: Viktor Němeček

Department: Department of Software and Computer Science Education

Supervisor: Mgr. Filip Děchtěrenko, Ph.D., Department of Software and Computer Science Education

Abstract: Abstract.

Keywords: key words

Obsah

Úvod	2
1 Základní pojmy	3
1.1 Šum	3
1.1.1 Barva šumu	3
1.2 Gabor patch	3
1.2.1 Definice	3
1.2.2 Použití	5
1.3 Úvod do teorie detekce signálu	5
1.3.1 Senzitivita	6
1.4 Entropie	8
1.5 Modely pozorovatele	8
1.5.1 d' mapa	9
1.5.2 Modely chování pozorovatele	9
2 Metody	12
2.1 Limitace	12
3 Měření	13
3.1 Metodika	13
3.2 Výsledky	13
4 Implementace	14
Závěr	15
A Přílohy	16
A.1 První příloha	16

Úvod

Následuje několik ukázkových kapitol, které doporučují, jak by se měla bakalářská práce sázet. Primárně popisují použití T_EXové šablony, ale obecné rady poslouží dobře i uživatelům jiných systémů.

1. Základní pojmy

1.1 Šum

V teorii detekce signálu šumem nazýváme jakoukoli nechtěnou (a typicky neznámou) modifikaci signálu.

1.1.1 Barva šumu

U aditivního¹ šumu můžeme měřit intenzitu šumu na různých frekvencích. Tu změříme tak, že na šum aplikujeme Fourierovu transformaci

Šumu se říká bílý šum, pokud by světlo, které by mělo stejnou distribuci intenzity napříč frekvencemi, jako daný šum (který ale vůbec nemusí být světelný), bylo bílé. Podobně známe například ještě růžový, červený či modrý šum.

Intenzita p všech zmíněných šumů na v na dané frekvenci lze vyjádřit jako $p = 1/f^\beta$, kde hodnota β je -1 pro modrý šum, 0 pro bílý, 1 pro růžový a 2 pro hnědý. Proto se růžový šum někdy též označuje jako $1/f$ šum. Pro ostatní barvy šumu není podobné označení běžné.

Pravděpodobnostní rozdělení jednotlivých složek Fourierovy transformace ale není definicí barvy šumu dáno. Pokud je rozdělení normální², řekneme, že se jedná o Gaussovský šum.

V této práci se budeme zabývat vizuálním šumem, tedy šumem, kde místo obvykle používané časové souřadnice použijeme dvě souřadnice prostorové, a měřenou hodnotou bude jas.

1.2 Gabor patch

Gabor filter (v českých textech někdy označovaný jako Gaborova vlnka) je lineární filtr používaný ve zpracování obrazu, chceme-li detekovat signál mající danou frekvenci a směr, který se vyskytuje kolem daného bodu.

1.2.1 Definice


Hodnotu filtru v daném bodě spočítáme jako součin dvou funkcí. První z nich je vždy sinus či cosinus (někdy uváděné v podobě komplexní exponenciály, pokud potřebujeme i reálnou, i imaginární složku). Jeho parametry určují, jaké vlastnosti má mít signál, který chceme detekovat. Druhé funkci říkáme obálka, a určuje, na jakém okolí daného bodu signál zkoumáme.

Funkce tedy vypadá jako


$$g(x, y) = \sin\left(2\pi\frac{x'}{\lambda} + \phi\right) * \text{obálka}(x', y'),$$

¹Šumu říkáme aditivní, pokud se jeho hodnoty přičítají k hodnotě signálu. Dále existuje například ještě šum multiplikativní či fázový (šum, který se projevuje krátkodobým fázovým posunem signálu).


²Nezáleží na tom, zda má normální rozdělení šum sám nebo jeho Fourierův obraz – tyto dvě vlastnosti jsou ekvivalentní.




(a) Modrý šum



(b) Bílý šum



(c) Růžový šum



(d) Červený, někdy též Brownův šum

Obrázek 1.1: Ukázky různých šumů.

kde vektor $(x', y')^T$ je vektor $(x, y)^T$ otočený o úhel, který svírá osa x se směrem, podél nějž chceme měřit signál (tento úhel budeme značit Θ), a posunutý do bodu, v němž chceme měřit signál, λ je frekvence signálu, který hledáme, a ϕ je fázový posun.

Jako obálka se používá dvojrozměrná Gaussova funkce, raised cosine, nebo prostá lineární funkce vzdálenosti.

Gaussovu funkci vyjádříme jako

$$\text{obálka}(x, y) = \exp\left(-\frac{x'^2 + y'^2}{2\rho}\right),$$

kde ρ je směrodatná odchylka Gaussovy křivky. Její výhodou je, že chování Gabor filtru, jehož obálku tvoří Gaussova funkce, je nejlépe popsáno. Raised cosine vyjádříme jako

$$\text{obálka}(x, y) = \begin{cases} \frac{\cos(\pi\sqrt{x'^2 + y'^2}/r) + 1}{2} & \text{pro } \sqrt{x'^2 + y'^2} \leq r, \\ 0 & \text{jinak,} \end{cases}$$

kde r je poloměr oblasti, v níž chceme signál detekovat. Výhodou raised cosine oproti Gaussově funkci je, že ve vzdálenosti alespoň r od středu filtru jeho hodnota nabývá nuly. Při výpočtech tedy stačí počítat s malou oblastí kolem středu (kdežto při použití Gaussovy funkce je nutné počítat s celým obrazem). Výhodou oproti lineární funkci vzdálenosti je, že raised cosine se pro většinu aplikací chová dostatečně podobně, jako Gaussova funkce.


1.2.2 Použití

Chceme-li detekovat signál ve vizuálním šumu, spočítáme hodnotu

$$s = \sum g(x,y) * n[x,y],$$

kde n je šum a sumu bereme přes všechny body (x,y) , v nichž jsme naměřili hodnoty šumu. Je-li hodnota s blízko nuly, signál v daném místě není přítomen, nebo je přítomen s jinými parametry. Vysoké hodnoty značí, že signál pravděpodobně přítomen je, hluboce záporné značí, že signál je přítomen, ovšem s fází posunutou π .

Gabor filter ale můžeme používat i k samotné tvorbě signálu. Chceme-li vytvořit v nějakém bodě signál, můžeme spočítat Gabor filter, jako bychom chtěli detekovat signál s právě takovými parametry, jaké má mít tvořený signál, a potom ho sečíst se šumem. Takto vytvořenému signálu budeme říkat Gabor patch.



Obrázek 1.2: Ukázky několika Gabor patchů. Všechny gabor patche jsou 100 pixelů široké i vysoké. Levý patch má $\Theta = 1/4\pi$, ostatní mají $\Theta = -1/4\pi$, levý má jako obálku Gaussovu funkci, prostřední dva raised cosine, pravý lineární funkci vzdálenosti, první, druhý a čtvrtý mají frekvenci (v cyklech na pixel) 0.1, třetí 0.02.

1.3 Úvod do teorie detekce signálu

Teorie detekce signálu řeší problém rozlišení dvou signálů, případně signálu a šumu. V této práci se budem zabývat problémem, kdy je potřeba rozhodnout, zda se v dané ploše nachází signál, či ne. Této úloze budeme říkat A/N problem, nebo pouze A/N.

V kontextu této úlohy můžou po odpovědi pozorovatele nastat čtyři možné situace:

	Signál je přítomen	Signál není přítomen
Pozorovatel odpoví kladně	<i>Hit</i>	<i>False alarm</i>
Pozorovatel odpoví záporně	<i>Miss</i>	<i>Correct rejection</i>

V této úloze se pozorovatel chová tak, že si zvolí kritérium (někdy též práh odpovědi), které udává, jaká musí být pravděpodobnost, že signál je přítomen, aby pozorovatel odpověděl kladně.

Poté pozorovatel provede pozorování, z něž získá informaci s . Poté spočítá hodnotu rozhodovací proměnné, tedy spočítá, jaká je pravděpodobnost, že je

signál přítomen. Tato pravděpodobnost se z Bayesovy věty spočítá jako

$$\begin{aligned} & P[\text{Signál je přítomen} | \text{Pozorování dalo informaci } s] = \\ &= \frac{P[\text{Pozorování dalo informaci } s | \text{Signál je přítomen}] * P[\text{Signál je přítomen}]}{P[\text{Pozorování dalo informaci } s]} \end{aligned}$$

Poté porovná tuto rozhodovací proměnnou s kritériem a podle výsledku tohoto porovnání odpoví.

Odsud je zřejmé, že zvyšováním kritéria zvedáme pravděpodobnost, že nastane miss, ale snižujeme pravděpodobnost false alarmu.

V souvislosti s A/N úlohou je ale ještě nutné zavést následující pojmy:

Definice 1. *Mějme pozorovatele p v úloze A/N. Potom jeho hit rate H_p definujeme jako*

$$P[\text{hit} | \text{Signál je přítomen}]$$

a jeho False alarm rate F_p jako

$$P[\text{False alarm} | \text{Signál není přítomen}].$$

1.3.1 Senzitivita

Jedním s dílčích problémů je též určení, jakou rozlišovací schopnost má daný pozorovatel na daný signál. Z předchozího odstavce by mělo být vidět, že kvantifikovat citlivost pouze pomocí hit rate není vhodné – například pozorovatel, který vždy odpoví „ano“ by měl v tomto případě optimální citlivost, což jistě nechceme. Taktéž není vhodné charakterizovat pozorovatele pomocí poměru hitů a false alarmů, optimalizace takového parametru by též vedla k scestnému nastavení kritéria.³

Při detekci signálu rozeznáváme dva druhy šumu. Šum vnitřní a šum vnější. Vnější šum je zkreslení dat, které se stane ještě mimo pozorovatele. Vnitřní šum je naopak šum, který je způsoben přímo algoritmem, který používá pozorovatel, aby dekodoval, zda signál je přítomen, či není.

Pro lepší porozumění případ z praxe. Necht je pozorovatel člověk, který není příliš pozorný a chystá se přejít silnici. Jeho (podvědomým) pozorováním je informace, která dorazí dle jeho mozku z periférií jeho sítnic, a signál, jehož přítomnost zkoumá, je, zda přijíždí auto. V takovém případě se v mozku spustí algoritmus, který převede pozorování na číslo X . Poznamenejme, že v mozku je hodnota tohoto čísla dobře kvantifikovaná, i když je mimo záběr této práce popisovat, co přesně z fyzikálního hlediska tato hodnota znamená. Pro porozumění stačí představa, že se jedná o frekvenci určitého druhu impulsu, které si mezi sebou neurony posílají. Mozek ví, jakou distribuci má náhodná veličina X v případě, že se auto blíží, a jakou má v případě, že nikoliv. Podle konkrétní hodnoty X kterou naměřil, se rozhodne, jestli auto přítomno není, a je tedy bezpečné silnici přejít, nebo zda je pravděpodobnost přijíždějícího auta dost vysoká na to, aby


³V typickém případě, který je popsán v následujících třech odstavcích, se pro kritérium jdoucí k nekonečnu tento poměr též blíží k nekonečnu. Dobrý pozorovatel by tedy téměř vždy odpovídal „ne“, optimální pozorovatel by neexistoval.

mělo smysl zvednout hlavu a podívat se příslušným směrem znovu s cílem získat lepší pozorování.

Praxe ukazuje, že v těchto situacích je rozdělení veličiny X často dobře aproximováno normálním rozdělením, a to jak v případě, že signál přítomen je, tak v případě, že přítomen není. Obě tato normální rozdělení navíc mají v tomto typickém případě stejný rozptyl a liší se jen svou střední hodnotou. Potom je přirozená otázka ptát se, jaký je rozdíl mezi jejich středními hodnotami (či lépe rozdíl mezi jejich středními hodnotami vydělený směrodatnou odchylkou).

Právě tuto hodnotu označíme jako hodnotu d' . Protože ale ne vždy je rozdělení normální, musíme nadefinovat hodnotu d' způsobem, která nebude závislá na rozdělení veličiny X .

Definice 2. *Nechť má pozorovatel p hit rate H_p a false alarm rate F_p obě ostře mezi jedničkou a nulou. Potom budeme jeho senzitivitu značit d' a spočítáme ji jako $d' = \Phi^{-1}(H_p) - \Phi^{-1}(F_p)$, kde Φ^{-1} je inverzní distribuční funkce normovaného normálního rozdělení.*



Obrázek 1.3: Závislost hit rate a false alarm rate pro různé hodnoty d' .

Nahlédneme, že senzitivita má následující vlastnosti:

- Pokud $d' = 0$, tak jsou indikátorové náhodné veličiny „Pozorovatel odpověděl kladně“ a „Signál je přítomen“ nezávislé.
- Pokud $d' > 0$, tak mají tyto dvě veličiny kladnou korelaci.
- Pokud skutečně má náhodná veličina X jak v případě, že signál přítomen je, tak v případě, že signál přítomen není, normální rozdělení lišící se pouze střední hodnotou, pak hodnota d' nezáleží na nastavení kritéria (samozřejmě krom případů, kdy kritérium nastavíme na plus nebo minus nekonečno, pak hodnota d' není dobře definovaná).

1.4 Entropie

Entropii (nazývanou též Shannonova entropie, aby nedošlo k záměně s entropií tak, jak jí chápe termodynamika) náhodné veličiny se v teorii informace rozumí střední hodnota informace, kterou nám hodnota této veličiny přinese. Například mějme náhodné veličiny X a Y . X nechť nabývá hodnoty 0 s pravděpodobností $1/2$ a hodnoty 1 s toutéž pravděpodobností. Y nechť nabývá hodnoty 1 s pravděpodobností 1 a hodnoty 0 s pravděpodobností 0. Je vidět, že pokud se dozvíme, jaké hodnoty nabývá veličina X , získáme více informace, než když zjistíme, jaké hodnoty nabývá Y .

Hodnotu informace, kterou nám přineslo zjištění, že náhodná veličina A nabývá hodnoty a , spočítáme jako

$$I(A = a) = \log_b \left(\frac{1}{P[A = a]} \right).$$

Jako základ logaritmu b se běžně používá 2 (což budeme dělat i v této práci), e nebo 10. Všimneme si, že toto vyjádření množství informace je konzistentní s intuitivní představou, že zjištění, že A nabývá nějaké nepravděpodobné hodnoty, je cennější, než zjištění, že nabývá nějaké pravděpodobné. Odsud tedy entropii $H(A)$ lze vyjádřit jako

$$H(A) = \mathbb{E}[I(A)] = \sum_{a \in \Omega} P[A = a] \log_2 \frac{1}{P[A = a]},$$

kde $\Omega = \{a \mid P[A = a] > 0\}$. Všimneme si, že podle tohoto vzorce je entropie veličiny X , tak jak byla nadefinována v předchozím odstavci, rovna jedné, kdežto entropie veličiny Y je rovna nule. To je konzistentní s jednou vlastností entropie, totiž s tím, že říká, že pokud označíme A^n řetězec prvků Ω s pravděpodobnostním rozdělením náhodné veličiny A , a K ideální kompresní algoritmus (tedy funkce z Ω^* do $0,1^*$), pak

$$\lim_{n \rightarrow \infty} \frac{\mathbb{E}[|K(A^n)|]}{n} = H(A).$$

Neformálně řečeno nám tedy entropie říká, kolik bitů v průměru potřebujeme na uložení hodnoty náhodné veličiny A .

Podobně jako u pravděpodobnosti můžeme poměrně přímočaře nadefinovat i podmíněnou entropii $H(A|B)$

1.5 Modely pozorovatele

V této práci se budeme zabývat úlohou, kdy pozorovatel hledá gabor patch v kruhovém poli, v němž se nachází růžový šum. Předchozí výzkum ukázal, že lidští pozorovatelé v této úloze využívají krátkých pohledů a rychlých pohybů očí. Jednomu takovému krátkému pohledu budeme říkat *fixace*. Očnímu pohybu budeme říkat *sakáda*. Pojem sakáda přirozeně aplikujeme i na simulované (tj. ne liské) pozorovatele, kde ho budeme chápat jako vektor v \mathbb{R}^2 mezi středy dvou po sobě jdoucích fixací. Jednotlivé fixace trvají přibližně 200–300 ms.

Abychom ale mohli hodnotit fixace lidského pozorovatele, potřebujeme mít nějaký model, který nám bude říkat, jak se chová optimální pozorovatel. Nejprve ale stručnou odbočku:

1.5.1 d' mapa

Ještě předtím, než začneme zjišťovat, podle jakého modelu se chová lidský pozorovatel, je nutné zjistit, kolik informace člověk jednou fixací získá. Je například zjevné, že kdyby jedním pohledem bez ohledu na to, kam se dívá, získal stejné množství informace o všech možných polohách cíle, jsou všechny modely ekvivalentní. Proto je potřeba najít tzv. d' mapu, funkci, která nám pro každé dva body x, y řekne, jakou hodnotu d' má lidský pozorovatel, pokud hodnotí pozici y a dívá se na pozici x . U pozadí s uniformními nebo téměř uniformními lokálními kontrasty lze tuto funkci zjednodušit, stačí, když budeme pro každý bod x vědět, jaká je hodnota d' pro rozhodování, zda je cíl v bodě x , pokud zafixujeme střed.

Předchozí výzkum ukázal, že u běžného člověka je d' mapa poměrně nepravidelná, ale dá se s přijatelnou přesností aproximovat mapou, kde křivky spojující body se stejnou hodnotou d' jsou tvořeny čtyřmi čtvrtelipsami (jednou v každém kvadrantu) se středem v počátku, s excentricitami a velikostí poloos danou hodnotou d' a individuálními vlastnostmi pozorovatele a cíle.

Ke kompletnímu vyjádření aproximace funkce d' potřebujeme celkem 6 hodnot, které závisí na konkrétním pozorovateli a cíli. Jedná se o hodnotu $d'_0 = d'(0,0)$, hodnot e_L , e_R , e_U a e_D , které určují vzdálenost ve čtyřech základních směrech takovou, že v nich je hodnota d' poloviční oproti počátku, a hodnotu β popisující sklon této funkce. Funkci d' pak vyjádříme jako

$$d'(x,y) = \frac{d'_0}{1 + \left(\frac{x^2}{e_H^2} + \frac{y^2}{e_V^2} \right)^\beta},$$

kde e_H je rovno e_L pro záporná x a e_R pro kladná, a e_V je rovno e_D pro záporná y a e_N pro kladná.

1.5.2 Modely chování pozorovatele

Všechny modely, které zde budeme zkoumat, vypadají tak, že mají tzv. *Mapu posteriorních pravděpodobností*. V této mapě je pro každou lokaci, kde by signál (též cíl) mohl být, uvedeno, jaká je pravděpodobnost, že se na ní cíl nachází vzhledem k informaci, kterou již o dané lokaci pozorovatel získal. Ve chvíli, kdy na nějaké lokaci pravděpodobnost přesáhne kritérium, pozorovatel ukončí hledání a ohlásí nalezení cíle na této lokaci.

V rámci předchozího výzkumu bylo otestováno mnoho modelů, jako například pozorovatel, který volí fixace náhodně nebo pozorovatel, který volí fixace co nejdále od míst, která již zafixoval. Všechny tyto modely se ale ukázaly jako nevhodné, vzhledem k tomu, že v praxi dosahují mnohem horších výsledků (měřeno pomocí střední hodnoty počtu fixací před nalezením cíle) než lidský pozorovatel.

MAP pozorovatel

Nejjednodušší model, který dosahuje podobných výsledků, jako lidský pozorovatel, je tzv. MAP⁴ pozorovatel, který vždy zafixuje lokaci, která má v jeho mapě posteriorních pravděpodobností nejvyšší hodnotu. Tento pozorovatel již dosahuje

⁴Z anglického „Maximum A posteriori Probability“.

podobných výsledků jako lidský, ale jeho strategie fixací neodpovídá strategii, jakou volí lidský pozorovatel. Lidský pozorovatel umístí svoji první fixaci do středu scény. Ostatní fixace jsou pak rozmístěny v okolí kružnice se středem ve středu scény a poloměrem rovným přibližně $2/3$ poloměru scény, s preferencí pro horní a spodní okraj. MAP pozorovatel oproti tomu vybírá každou lokaci se zhruba stejnou pravděpodobností.

Ideální Bayesovský pozorovatel

Ještě o malinko lepších a hlavně statisticky lidskému pozorovateli bližších výsledků bosahuje model Ideálního Bayesovského pozorovatele.

Ideální Bayesovský pozorovatel (dále IBO) je pozorovatel, který $T + 1$ lokaci vybírá tak, aby maximalizoval pravděpodobnost, že v následujícím kroku odhalí cíl. Vybere tedy lokaci

$$k_{opt}(T + 1) = \arg \max_{k(T+1)} \left(\sum_{i \in L} p_T(i) P[p_{T+1}(i) \geq c | i, k(T + 1)] \right), \quad (1.1)$$

kde p_N je mapa posteriorních pravděpodobností po N -té fixaci, L je množina všech potenciálních lokací cíle a c je kritérium, které musí hodnota v mapě posteriorních pravděpodobností překročit, aby bylo ukončeno hledání a nahlášeno nalezení cíle. Výraz $P[p_{T+1}(i) \geq c | i, k(T + 1)]$ pak tedy znamená „pravděpodobnost, že po $T + 1$ fixaci bude ukončeno hledání a nhlášen signál v lokaci i , za podmínky, že tam signál opravdu je a byl zafixován bod $k(T + 1)$ “.

IBO však ale též není příliš pravděpodobný kandidát na model, podle něž se lidé chovají. Ač má jeho vyhledávání podobné statistické vlastnosti, jako vyhledávání lidského pozorovatele, můžeme si všimnout, že přinejmenším přímočaré vyhodnocení výrazu (1.1) je kubické v počtu potenciálních lokací (výpočet druhého činitele součinu v sumě je lineární, suma sama je přes lineárně mnoho členů, a vnější maximum má též lineárně mnoho možných voleb $k(T + 1)$). Lidský pozorovatel při vyhledávání volí další fixaci přibližně třikrát až čtyřikrát za vteřinu, je tedy nepravděpodobné, že by lidský mozek dokázal takový výpočet provést.

ELM pozorovatel

ELM⁵ pozorovatel je pozorovatel, který při výběru následující fixace minimalizuje střední hodnotu entropie náhodné veličiny určující lokaci cíle. Tu spočítáme jako

$$\mathbb{E}[H(T + 1) | k(T + 1)] = -\mathbb{E} \left[\sum_{i \in L} p_{T+1}(i) \log_2 p_{T+1}(i) | k(T + 1) \right]. \quad (1.2)$$

V ZDROJ09 se však zjistilo, že vyjádření hodnoty entropie podle vzorce (1.2) je sice netriviální, ale lze ho dobře aproximovat případem, kdy pošleme v limitě $|L|$ do nekonečna. Pak dostáváme výraz

$$\mathbb{E}[H(T + 1) | k(T + 1)] = H(T) - \sum_{i \in L} p_T(i) d'^2(i - k(T + 1)),$$

⁵z anglického „Entropy limit minimization“.

kde v posledním členu bereme lokace jako vektory od počátku k nim. Člen $H(T)$ navíc nezávisí $k(T + 1)$, takže s ním vůbec nemusíme počítat a k minimalizaci entropie nám stačí maximalizovat hodnotu sumy.

2. Metody

2.1 Limitace

Při návrhu experimentu jsme narazili na několik problémů, které mohou vnést nepřesnosti do měření, ale jejichž řešení je mimo rozsah této práce. Konkrétně se jedná o následující obtíže:

- Vjemy lidského pozorovatele neodpovídají příliš dobře vjemům simulovaného ideálního pozorovatele. Aby si tyto vjemy odpovídaly, alespoň přibližně, museli bychom každému pozorovateli změřit jeho vlastní d' mapu. Měření d' mapy ale i v té nejminimalističtější variantě, která se používá, trvá nejméně jeden pracovní den. Druhým důvodem, proč mohou být vjemy rozdílné i v případě, že by konstatnty d' mapy vyšly pozorovateli stejně, jaké byly použity, je, že tato naměřená d' mapa odpovídá situaci, kdy je scéna se šumem umístěna tak daleko od pozorovatele, aby ji viděl pod zorným úhlem 15° . To při velikosti scény v našem případě odpovídá vzdálenosti pozorovatele a zařízení přibližně 65 cm. V našich experimentech nebyla vzdálenost pozorovatele od scény hlídána.
- Okraj

3. Měření

3.1 Metodika

3.2 Výsledky

4. Implementace

Tady bych dal nejspíše nějaký high-level přehled a potom pár slov o každém zdrojovém souboru.

Závěr

A. Přílohy

A.1 První příloha